



МГТУ им. Н.Э. Баумана

**Кафедра «Теоретическая информатика
и компьютерные технологии»**

Автоматическая оптимизация планов выполнения SQL-запросов

Руководитель: Непейвода А.Н.

Старовойтов А.И.

Оптимизатор запросов

Компонент СУБД, который преобразует декларативный SQL-запрос в физический план исполнения.

- Один SQL-запрос допускает множество эквивалентных планов.
- Разные порядки соединений и физические операторы дают различную стоимость.
- Поиск оптимального плана является NP-полной задачей в общем случае.
- Выбор неудачного плана может увеличить время выполнения на порядки.



Цель и задачи

Цель


Разработать и реализовать оптимизатор подмножества SQL-запросов на основе архитектуры Cascades, а также создать каркас для его итеративного улучшения.

- Формализовать поддерживаемое подмножество SQL и реляционной алгебры.
- Реализовать Метод и алгоритм поиска физического плана.
- Разработать правила трансформации и реализации операторов.
- Реализовать стоимостную модель и метод ветвей и границ.
- Сравнить пространство поиска с планами Microsoft SQL Server.




Эффект выбора плана

Наивный план



Оптимизированный план



Поддерживаемое подмножество SQL


```
SELECT projection  
FROM tables  
JOIN ... ON predicate  
WHERE predicate  
GROUP BY attributes  
ORDER BY attributes
```

- Основа грамматики: диалект PostgreSQL.
- Поддержаны SELECT, FROM, WHERE, JOIN, GROUP BY, ORDER BY.
- Соединения: INNER, LEFT, RIGHT, FULL, CROSS.
- Агрегации: SUM, COUNT, COUNT(*).
- Предикаты: сравнения, AND, OR, NOT, BETWEEN, IN, проверки NULL.




Cascades и Memo

- Cascades хранит пространство поиска в структуре Memo.
- Группа Memo объединяет логически эквивалентные выражения.
- Групповое выражение содержит оператор и ссылки на дочерние группы.
- Поиск управляется стеком задач.



Процесс обработки запроса



Реляционная алгебра

- $\sigma_p(E)$ — фильтрация кортежей по предикату p .
- $\pi_{\bar{a}}(E)$ — проекция выбранных атрибутов.
- $E_1 \times E_2$ — декартово произведение отношений.
- $E_1 \bowtie_p E_2$ — соединение отношений по предикату.
- $\gamma_{\bar{g}; \bar{f}}(E)$ — группировка и вычисление агрегатов.
- $\tau_{\bar{a}}(E)$ — сортировка результата.

Форма запроса

$$\pi_{\bar{a}}(\sigma_p(E_1 \times \dots \times E_n)), \quad \gamma_{\bar{g}; \bar{f}}(\sigma_p(E_1 \times \dots \times E_n))$$



Трансформации

- коммутативность и ассоциативность соединений;
- разбиение, объединение и проталкивание фильтров;
- проталкивание проекций через соединение;
- преобразование IN в цепочку сравнений;
- перенос фильтра в предикат соединения;
- внешнее соединение во внутреннее;
- проталкивание и перестановка агрегации.

Реализации

- SeqScan, IndexScan;
- Filter, Projection;
- NestedLoopJoin, HashJoin, MergeJoin;
- HashAggregate;
- StreamAggregate.



Стоимостная модель

Отсечение ветвей

Если для группы G и свойства P уже найден план стоимости C^* , то физическое выражение e можно не рассматривать при выполнении условия:

$$C_{local}(e) + \sum_{i=1}^k LB(G_i, P_i) \geq C^*.$$

Физический оператор	Формула стоимости
Последовательное сканирование	$100\ n$
Проекция	$22\ n_{out}$
Сортировка	$11\ n(\lfloor \log_2 n \rfloor + 1)$
Агрегация	$510\ n$
Потоковая агрегация	$130\ n$
Соединение вложенными циклами	$70\ n_l n_r$
Декартово произведение	$104\ n_l n_r$



Дифференциальный анализ планов

Основная идея


Проверяем, достигим ли план, построенный промышленной СУБД, при текущем наборе правил и условиях активации. Цель: найти недостающие правила и уточнить правила активации.

1. Генерируется случайный SQL-запрос из поддерживаемого подмножества.
2. Microsoft SQL Server строит физический план.
3. ShowPlanXML конвертируется во внутренний формат проекта.
4. Запускается оптимизатор с отключенным B&B.
5. Структурно соотносится получившееся пространство поиска и эталонный план.




Пример найденного расхождения

```
SELECT markets.id AS c2619  
FROM markets CROSS JOIN users CROSS JOIN books  
WHERE markets.region != 'AMERICA';
```



План Microsoft SQL Server



План модельной СУБД




Результаты проверки пространства поиска

Показатель	Значение
Количество сгенерированных запросов	1000
Достижимый план промышленной СУБД	251
Недостижимый план промышленной СУБД	244
Пропущено	505
Ошибки преобразования плана	496
Ошибки преобразования из-за исключений	9
Ошибки получения плана Microsoft SQL Server	0
Среднее расстояние до ближайшего плана	2.37

- 25% от общего числа планов совпали.
- 25% требуют уточнения правил.
- 50% требуют расширения набора операторов.







- Сравнивались режимы Naive и Optimized.
- Использованы запросы Star Schema Benchmark.
- На выбранном наборе тестов получено ускорение 2.5–30 раз.



Калибровка стоимостной модели



Физические операторы



Случайные запросы

- Формулы стоимости откалиброваны по бенчмаркам физических операторов.
- Общая стоимость планов согласована с реальным временем исполнения.

